

ИНТЕЛЛЕКТУАЛЬНЫЙ АНАЛИЗ И ВИЗУАЛИЗАЦИЯ ДАННЫХ

Лекция · поток 3 курса (две группы)

Модуль 1

Методология анализа и визуализации данных

Модуль рабочей программы курса ИАиВД

Место дисциплины в цикле работы с данными: объект и предмет, проблема «последней мили», эволюция аналитики от статистики до XAI

Занятие 1.1

Место дисциплины, эволюция области и организация курса

Лекция · 90 минут · 2 академических часа

Дорожная карта и треки BI/ML · Проблема «последней мили» · От Тьюки и Тафти до Self-Service BI и XAI

Большаков Анатолий Афанасьевич
доцент, канд. техн. наук

05.09.2026
Санкт-Петербург

Организация курса: единая теория, два трека

Общий теоретический фундамент для всего потока; практика и проект — по профильным трекам команды

Теория — совместно

Лекции для всего потока: формируем общий язык аналитиков и инженеров.

Содержание блока

- Когнитивная психология восприятия.
- Информационный дизайн.
- Методы оценки моделей.

Практика — по трекам

Проектирование интерфейсов на сквозном датасете SOC.

Зачем два трека

У команд разный стартовый порог: трек BI не требует программирования, трек ML предполагает входной контроль по Python. Обе роли востребованы индустрией.

BI-аналитика — базовый (по умолчанию) · Qlik Sense Desktop

ML-инжиниринг — по заявлению команды · Python / Taipy / Plotly

Выбор трека фиксируется на практикуме 1.4.

Два трека — не «сильные и слабые», а **разные стартовые пороги и разные роли**

Базовый трек: дескриптивная аналитика и разведочный анализ данных (EDA)

Целевая аудитория

Базовый трек — выбирается по умолчанию, программирование не требуется.

Инструмент

Qlik Sense Desktop — ассоциативная модель данных: миллионы строк исследуются в оперативной памяти, без написания кода.

Сквозной кейс

Датасет центра мониторинга информационной безопасности (SOC): поиск аномалий в сотнях тысяч алертов.

Задачи трека

- Загрузка и подготовка данных.
- Анализ множеств (**Set Analysis**).
- Разведочный анализ (EDA): выявление аномалий в исторических данных.
- Конструирование интерактивных дашбордов.

Результат

Аналитик SOC за пару кликов переходит от общей картины к расследованию конкретной аномалии.

Фокус трека — дескриптивная аналитика: **отвечаем на вопрос «Что произошло?»**

Интеграция предобученных моделей и методов объяснимого ИИ в веб-приложения

Целевая аудитория

По заявлению команды при успешном прохождении входного контроля по Python.

Инструменты

Python, фреймворк **Taipy**, библиотека **Plotly** — разработка веб-приложений (Data Apps).

Сквозной кейс

Тот же датасет SOC: интерфейс, где предсказание сопровождается визуальным объяснением.

Задачи трека

- Инференс предобученных ML-моделей (**joblib**).
- Асинхронные вызовы моделей (Live Prediction).
- Визуализация XAI: графики **SHAP** и **PDP** в пользовательском интерфейсе.

Результат

Приложение не просто выдаёт предсказание, а визуально доказывает аналитику SOC, почему модели можно доверять.

Фокус трека — предиктивная аналитика: «что произойдёт» + «почему модели можно доверять»

Дорожная карта курса и аттестация

15 недель командной работы (2–3 человека), три контрольные точки, зачёт с оценкой

Итоговый контроль

Классического экзамена по билетам не будет. Форма итогового контроля — **зачёт с оценкой** в формате публичной защиты группового проекта.

Как складывается оценка

Командная защита проекта по рубриктору + индивидуальные ответы на вопросы. «Спрятаться в команде» не получится.

Раздаточный материал

«Дорожная карта курса и рубрикатор оценки группового проекта» — в СДО.

КТ 1 · Архитектурное ревью — нед. 13, после модуля 3

Перекрёстная оценка: команды рецензируют интерфейсы друг друга.

КТ 2 · Предзащита — нед. 15

Работоспособность приложений, критические ошибки, корректность формул.

КТ 3 · Итоговая защита — сессия

Аналитическая обоснованность, информационный дизайн, техническая реализация.

Рубрикатор: аналитика **30 %** · информационный дизайн **30 %** · техническая реализация **40 %**

Объект и предмет дисциплины

Переход от математических алгоритмов к человекоцентричным интерфейсам

Объект

Массивы данных, результаты работы ML-алгоритмов и аналитические системы.

Примеры

- Логи SIEM: миллионы событий и алертов.
- Выводы моделей: вероятности, классы, метрики.
- Аналитические отчёты и выборки.

Предмет

Методы трансформации алгоритмических вычислений в визуальные интерфейсы поддержки принятия решений.

Инструменты трансформации

- Визуальные кодировки: длина, позиция, цвет, тренд.
- Принципы информационного дизайна.
- Методы объяснимого ИИ (XAI).

Курс — о том, что происходит с вычислениями, когда на них смотрит живой человек

Разрыв в Data Science

Высокая точность математической модели не гарантирует её внедрение в бизнес-процессы

Язык Data Science

- ROC AUC
- F1-score
- Градиентный бустинг
- «Модель сходится»

Так говорит датасаентист, отчитываясь о качестве модели

разрыв

Язык бизнеса

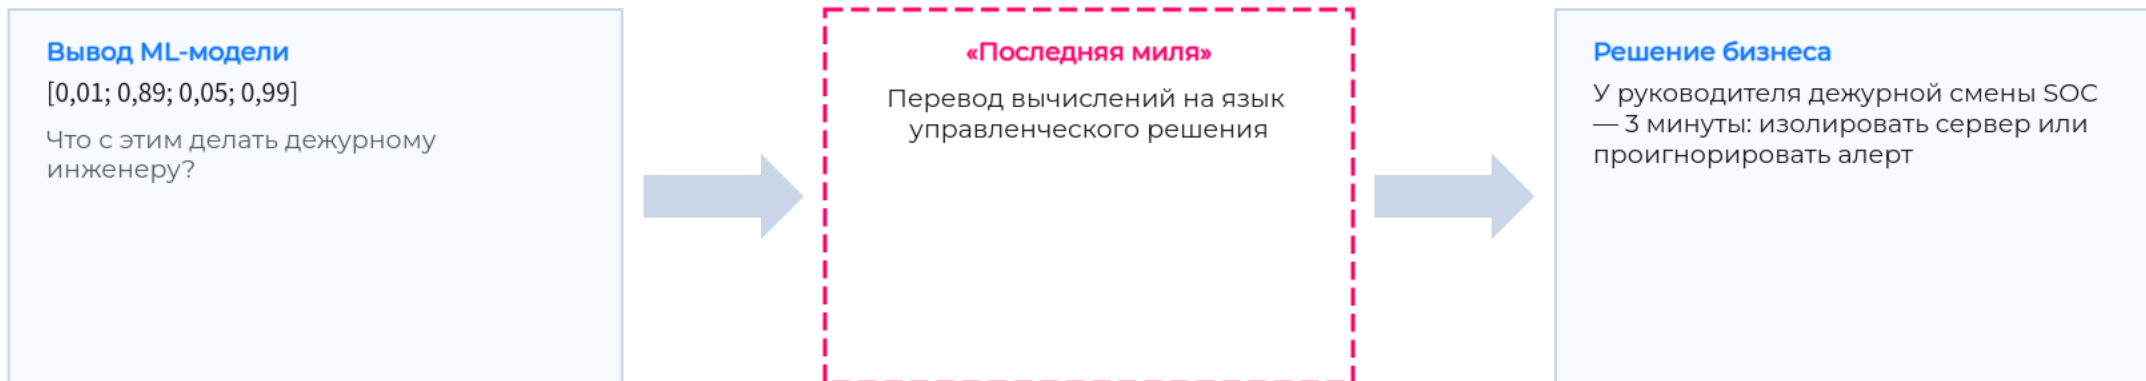
- Снижение рисков
- ROI
- SLA
- Стоимость ошибки

Так мыслит руководитель SOC, принимая решение

Между математикой и бизнесом — пропасть: F-score 0,9 ничего не говорит руководителю

Проблема «последней мили» (The Last Mile Problem)

Самая сложная задача — «доставить» математический вывод в мозг бизнес-заказчика



Как в логистике самый сложный и дорогой этап — доставка посылки от распределительного центра до двери клиента, так и в Data Science самое сложное — «доставка» математического вывода в мозг заказчика.

Тысячи моделей легли «в стол», потому что их авторы не объяснили бизнесу, почему алгоритму можно доверять.

Аналитик данных — это **переводчик** с машинного языка на язык управленческих решений

Визуализация — мост через разрыв

Инструменты курса переводят математическую абстракцию в визуальные кодировки: длину, цвет, позицию, тренд

Сырые данные и вычисления: логи SIEM · SQL-запросы · `model.fit()` и `model.predict()` · метрики качества



Визуальный интерфейс поддержки решений
Дашборд Qlik Sense (трек BI) · Веб-приложение Taipy (трек ML)



Действие человека: руководитель дежурной смены SOC за 3 минуты принимает решение — изолировать сервер или проигнорировать алерт

Аналитика не имеет ценности, если она не приводит к решениям (К. Андерсон)

Роли индустрии данных и треки курса

Две роли-«строителя» соответствуют трекам курса; аналитик SOC — сквозной заказчик семестра

BI-аналитик

Исторические данные, дашборды — вопрос «что произошло?»

Data Scientist — смежная роль

Модели и метрики — «что произойдёт?»; математика — за рамками курса

ML-инженер

Промышленная эксплуатация моделей (Data Apps)

Аналитик SOC

Решения в условиях потока алертов — главный потребитель аналитики

Маттинг на курс

Трек «**BI-аналитика**» → роль BI-аналитика

Трек «**ML-инжиниринг**» → роль ML-инженера


Аналитик SOC — сквозной заказчик всех проектов семестра

Аналитик SOC появится на следующей лекции как главный герой сквозного кейса.

Обе роли-строителя работают на одного заказчика — **аналитика SOC**

Эволюция области: от статистики к дизайну

Инструменты визуализации — исторический ответ на кризисы обработки информации




Современные графики и подходы появились не случайно — это эволюционный ответ науки на рост объёмов данных. Каждый следующий этап решал кризис предыдущего.

Каждый этап эволюции находит своё место в модулях курса

До 1970-х: подтверждающий анализ (CDA)

Данные использовались исключительно для проверки заранее сформулированных гипотез



Визуализацию считали необязательной: строгих формул статистики якобы достаточно. Данные были «немыми» — они не могли подсказать ничего сверх исходной гипотезы.

Классическая статистика отвечала только на заранее заданный вопрос — **но не помогала увидеть неизвестное**

1977 год: разведочный анализ данных (EDA)

Визуализация как инструмент поиска неизвестных аномалий и гипотез

Джон Тьюки (John Tukey)

Книга «Exploratory Data Analysis», 1977

Революция подхода

Прежде чем проверять гипотезы, нужно позволить данным самим подсказать эти гипотезы — и лучший способ сделать это: **визуализировать данные**.

Связь с курсом

Весь модуль 2 построен на подходе Тьюки: аномалии в датасете SOC ищем визуально, до `model.fit()`.

Вклад Тьюки

— «Ящик с усами» (box plot) и стеблевые диаграммы — введены в широкий оборот.

— Гистограммы и точечные графики, известные задолго до него, — превращены в систематический инструмент разведки.

Зачем это аналитику SOC

Прежде чем блокировать IP-адрес, аналитик визуально оценивает распределение: не прячется ли за выбросом таргетированная атака.

«Позвольте данным самим подсказать гипотезы» — основа модуля 2

1983 год: информационный дизайн

Превращение визуализации из «рисования» в строгую инженерную дисциплину

Эдвард Тафти (Edward Tufte)

«The Visual Display of Quantitative Information», 1983

Контекст

С появлением ПК графики стали «украшать»: тени, 3D, градиенты. Тафти ввёл математическую метрику мусора.

Принцип

Каждый пиксель, не отражающий значение данных, — информационный мусор (chartjunk), и он должен быть удалён.

Концепция Data-ink ratio

$$\text{Data-ink ratio} = \frac{\text{«чернила» данных}}{\text{все «чернила» графика}}$$

Связь с курсом

Аналитик SOC работает в условиях стресса и лимита времени (SLA): 3D-эффекты и толстые сетки крадут миллисекунды на расшифровку мусора.

За визуальный шум в проектах — **штраф по рубриктору**: 30 % оценки — информационный дизайн.

График не должен быть красивым — он должен быть честным и эффективным

1984 год: психофизика кодировок

Математическое обоснование точности человеческого восприятия геометрии

Уильям Кливленд и Роберт Макгилл

Статистик и психолог; эксперименты по точности считывания графиков, 1984 — направление graphical perception

Что сделали

Провели тесты на людях на стыке математики, биологии и когнитивной психологии: измерили, насколько точно мозг считывает разные визуальные кодировки.

Результат

Строгая иерархия точности кодировок — от позиции на шкале до интенсивности цвета.

Логика эволюции

- Тьюки сказал, *что* делать: исследовать данные визуально.
- Тафти сказал, *как*: чисто, без мусора.
- Кливленд и Макгилл ответили, *какие формы* работают лучше всего.

Связь с курсом

Матрица выбора диаграмм (Модуль 2) опирается на эту иерархию: мы выбираем графики на длине и позиции, а не на углах и площадях.

Психофизика данных: **какие формы** мозг считывает **точнее всего**

Иерархия точности визуальных кодировок

Длина оценивается мозгом точнее, чем площадь или интенсивность цвета




Рисунок 1.1.5 — иерархия кодировок по экспериментам У. Кливленда и Р. Макгилла (1984)

Круговая диаграмма использует угол и площадь — **самые неточные каналы восприятия**

2000–2010-е: аналитика самообслуживания (Self-Service BI)

Переход возможности анализа от ИТ-инженеров напрямую к бизнес-пользователям

OLAP-эпоха: ИТ-отдел как «узкое горлышко»

1. Руководитель SOC просит отчёт по инцидентам за месяц.
2. ИТ-отдел пишет SQL-запросы и собирает данные.
3. Через неделю — статичный PDF-отчёт.
4. Новый разрез данных (например, по IP-адресу) — цикл повторяется заново.

Self-Service BI: интерактивная фильтрация

- Миллионы строк загружаются в оперативную память.
- Пользователь сам фильтрует данные и меняет визуализации без кода.
- Платформы нового поколения: Qlik Sense, Tableau.

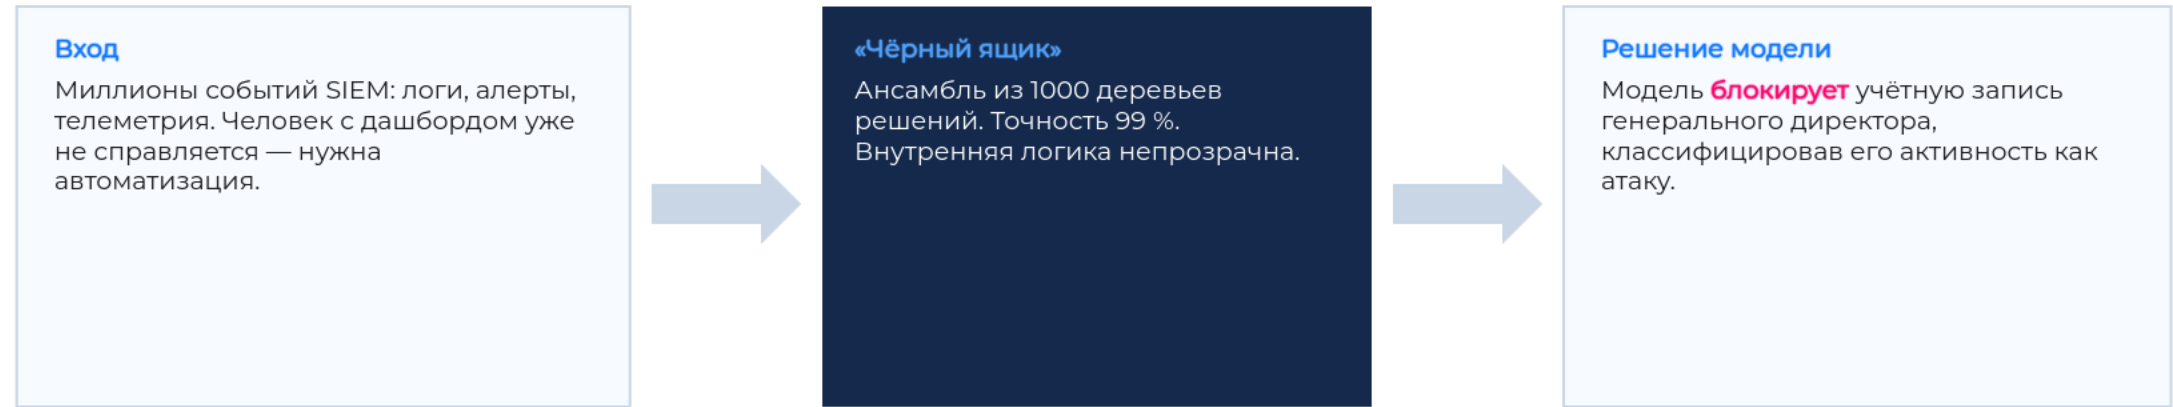
Связь с курсом

Это эпоха трека BI: ассоциативная модель Qlik Sense позволяет аналитику мгновенно переходить от сотен тысяч алертов к конкретной аномалии.

От статичных отчётов ИТ-отдела — к самостоятельному исследованию данных бизнесом

Современность: кризис «чёрного ящика»

Экстремально высокая точность ансамблевых моделей породила полное непонимание их логики



Директор в ярости требует объяснений. Датасаентист отвечает: «Не знаю — модель состоит из 1000 деревьев, но историческая точность 99 %».

В этот момент модель отправляется в корзину: в критических отраслях (ИБ, медицина, финансы) бизнес и регуляторы не принимают слепые алгоритмические решения.

Точность 99 % не спасает модель, которой бизнес не может доверять

2017 год: объяснимый ИИ (Explainable AI / XAI)

Вскрытие «чёрного ящика» математическим аппаратом теории игр

Скотт Лундберг, Су-Инь Ли

2017: значения Шепли из теории коалиционных игр → метод **SHAP**

Кристоф Молнар

Монография «Interpretable Machine Learning» — систематизация методов XAI

Суть подхода

Для каждого предсказания вычисляется вклад каждого признака: что повысило вероятность вердикта, а что — снизило.

Объяснение для аналитика SOC

Модель заблокировала директора, потому что:



Обфусцированная командная строка — **существенно повысила** вероятность вердикта «атака»



Скрытое выполнение PowerShell — **повысило** вероятность



Время суток — **снизило** вероятность

Модель превращается из автономного «терминатора» в **прозрачного советчика** — основа трека ML

Этапы эволюции и модули курса

Каждая историческая веха подробно разбирается в соответствующем модуле программы

Исторический этап / концепция	Автор / год	Где изучается в курсе
Разведочный анализ (EDA)	Дж. Тьюки, 1977	Модуль 2 · Лекция 2.4
Data-ink ratio: борьба с визуальным мусором	Э. Тафти, 1983	Модуль 2 · Лекция 2.2
Психофизика кодировок	У. Кливленд, Р. Макгилл, 1984	Модуль 2 · Лекция 2.1
Аналитика самообслуживания (Self-Service BI)	Развитие индустрии, 2010-е	Практики трека BI (Qlik Sense)
Значения Шепли в ML (SHAP)	С. Лундберг, С.-И. Ли, 2017	Модуль 3 · Лекция 3.4

Таблица 6.1 — связь этапов эволюции области с модулями курса

Структура курса повторяет логику эволюции области: от EDA до объяснимого ИИ

Ключевая литература курса

Три книги — компас курса: сторителлинг, культура данных, объяснимый ИИ

1. К. Нассбаумер Нафлик. «Данные: визуализируй, расскажи, используй. Сторителлинг в аналитике» (2025).

Основная книга по сторителлингу и борьбе с визуальным мусором.

3. C. Molnar. «Interpretable Machine Learning: A Guide for Making Black Box Models Explainable» (электронный ресурс).

Базовый труд по методам XAI: SHAP, PDP и другие техники интерпретации моделей.

2. К. Андерсон. «Аналитическая культура. От сбора данных до бизнес-результатов» (2017).

Как внедрять data-driven подход: аналитика ценна, только когда приводит к решениям.

Где искать полный список

Полный перечень литературы — в РПД; первоисточники исторического блока — в списке источников занятия 1.1.

По РПД Молнар и Андерсон — дополнительная литература, но для нашего курса они ключевые.

Три книги — компас курса: сторителлинг, культура данных, объяснимый ИИ

Резюме: цель дисциплины

Курс не про математику алгоритма, а про интерфейс между алгоритмом и человеком

Это не курс по рисованию красивых картинок и не курс по математическому выводу алгоритмов — их вы изучаете на других дисциплинах.

**Трансформация сырых вычислений в научно обоснованные визуальные интерфейсы
поддержки принятия решений**

Научный фундамент курса: гештальтпсихология · психофизика визуальных кодировок · методы объяснимого ИИ (XAI).
Сквозной полигон семестра — логи системы безопасности (SIEM): вы спасаете аналитиков SOC от когнитивной перегрузки.

Наша работа — закрыть «последнюю милю» между вычислением и управленческим решением

Итоги занятия и самостоятельная работа

Что освоили на лекции и что нужно сделать до установочного практикума 1.4

Что освоили сегодня

- 01 Объект и предмет дисциплины.
- 02 Роли индустрии данных и ИБ.
- 03 Суть проблемы «последней мили».
- 04 Вехи эволюции: EDA, Data-ink ratio, психофизика, Self-Service BI, XAI.
- 05 Дорожная карта: 15 недель, 3 контрольные точки.
- 06 Треки BI и ML и их инструменты.

Самостоятельная работа к занятию 1.4

- 1. Изучить РПД, рубрикатор и раздаточный материал «Дорожная карта курса и рубрикатор оценки группового проекта».
- 2. Сформироваться в команды (2–3 человека).
- 3. Подготовить командное решение о треке (фиксация — на 1.4).
- 4. Подготовить рабочие места по чек-листу ПО: Qlik Sense Desktop или Python / VS Code / Taipy.
- 5. Прочитать: К. Андерсон, «Аналитическая культура» (главы о data-driven подходе).

Далее — лекция 1.2: погружение в предметную область SOC

Контрольные вопросы

Самопроверка по итогам лекции: вопросы 1–4 — теория, 5–6 — организация курса

1. В чём заключается суть проблемы «последней мили» в Data Science?
2. Почему ML-модель с высокой точностью (Accuracy) может быть отклонена бизнес-заказчиком в промышленной эксплуатации?
3. Какой вклад внёс Джон Тьюки в современный анализ данных? В чём отличие EDA от подтверждающего (confirmatory) анализа?

4. Почему концепция объяснимого ИИ (XAI) стала актуальной именно в последнее десятилетие?
5. Какие роли существуют в индустрии данных и ИБ? Каким трекам курса они соответствуют?
6. Назовите три контрольные точки (КТ) при подготовке группового проекта в рамках курса.

Анонс: лекция 1.2 — погружение в предметную область SOC

Открываем полигон курса — учебный датасет на основе реальных логов центра мониторинга безопасности

Что разберём на лекции 1.2

- Что такое **SIEM** и **SOC**: как устроен центр мониторинга ИБ.
- Архитектура сквозного датасета алертов.
- Анатомия карточки инцидента: из каких полей состоит кибералерт.
- Почему человек — обязательное звено системы (**Human-in-the-loop**).

Откроем полигон курса — учебный датасет на основе реальных логов SOC (**~274 000 строк**).

Важно про данные

Датасет синтетический: построен на основе реальных паттернов логов — вопросы персональных данных не возникают.

Поймём, с чем именно будем работать весь семестр.

Аналитик SOC — **главный герой** сквозного кейса семестра

Вопросы?

Интеллектуальный анализ и визуализация данных · занятие 1.1 · Большаков А.А., ВШТИИ