
От данных к решениям

Роль визуализации в цикле ML

Занятие 1.2 · Лекция · 90 минут

Интеллектуальный анализ и визуализация данных · Модуль 1

Интегрированный поток: бакалавриат и магистратура

Мост: что сделано и что сегодня

Неделя 1

- Правила игры: треки, рубрикатор, команды
- Практикум 1.4: рабочие среды проверены

Сегодня

- Открываем сквозной кейс: SOC и карточка инцидента
- В 12:00 — практика 1.5: фиксация треков, проверка инструментов

Масштаб задачи

240 000

карточек-алертов в сквозном датасете курса
(учебный датасет на основе реальных логов SOC)

Откуда берётся поток

тысячи событий в секунду → сбор и корреляция (SIEM) → карточки-алерты

Шум преобладает

В отдельные периоды **более половины** карточек — ложноположительные срабатывания

Проверка каждой — минуты времени дежурного аналитика

Цена ошибок сортировки

Пропущенный инцидент

Компрометация данных, простой бизнеса, репутация

Ложная тревога

Остановленные процессы, потраченные часы смены

«Усталость от алертов»

Неделя пустышек — аналитик закрывает карточки по привычке.

Однажды он закрывает **настоящий инцидент**.

Формула мира, в котором мы работаем

- 01 Огромный поток
- 02 Шум преобладает
- 03 Обе ошибки дороги
- 04 Время каждой проверки ограничено

Название дисциплины — две половины конвейера



Интеллектуальный анализ

Визуализация данных

Половины не существуют друг без друга

Анализ без визуализации — «чёрный ящик», которому не доверяют

Визуализация без анализа — красивые картинки над шумом

Визуализация на каждом шаге ML-цикла

- Разведка данных → **модуль 2**
- Оценка модели → **3.1–3.2**
- Объяснение модели (XAI) → **3.3–3.4**
- Коммуникация результата → **модуль 4**

SOC — центр мониторинга ИБ

Непрерывный мониторинг, выявление и координация реагирования

Дежурные аналитики работают посменно, круглосуточно.


Их единица работы — **карточка**.

SIEM — система сбора и корреляции

Собирает события со всех устройств → нормализует → применяет **правила корреляции**

Сработало правило → SIEM создаёт **алерт** — карточку для проверки

Конвейер сортировки алертов



Сортировка алертов (триаж)

Аналитик проверяет карточку и выносит вердикт:

«Инцидент» — тревога подтверждена, запускается реагирование

«Ложноположительное срабатывание» — тревога ложная, карточка закрыта

По этой метке размечен наш датасет

Критичность — первый, грубый фильтр

Правило SIEM присваивает приоритет:

критическая · высокая · средняя · низкая

Критические проверяются первыми. Но правила ошибаются:

«низкая» критичность не гарантирует, что атаки нет

Где самое слабое звено конвейера?

SIEM обрабатывает миллионы событий в секунду.

Проверяет карточки — **человек**:

скорость мышления, внимание падает к третьему часу смены

Карточка инцидента: четыре группы полей

Карточка инцидента

Идентификаторы

incident_id · timestamp

Поведенческие поля

CMDLINE · processName · objectValue

Инфраструктурные поля

src · dst · suser

Предварительная оценка

Правило корреляции SIEM · Критичность

Идентификаторы

`incident_id` — уникальный номер карточки

Ссылка на событие в дашборде, отчёте, коде

`timestamp` — момент события

Ночная суббота и рабочий полдень — разные миры

Поведенческие поля: «что делал процесс»

`CMDLINE` — полная командная строка запуска

`processName` — имя исполняемого файла

`objectValue` — значение объекта: ключ реестра, файл, параметр

Типовые программы работают с типовыми командами.

Нестандартное в командной строке — заслуживает взгляда

Инфраструктурные поля: «кто и куда»

`src` — IP источника (рабочая станция, сервер)

`dst` — IP цели обращения

`suser` — учётная запись

Внутренний или внешний адрес, привилегии учётной записи — каждый факт меняет прочтение карточки

Предварительная оценка

Правило корреляции SIEM — что именно «насторожило» систему

Критичность — предварительный приоритет

Это то, что система уже «подумала» — не приговор

Демонстрационная карточка

```
INC-2026-004817 · 2026-08-14 02:31:07 · Критичность: Высокая
Правило: Подозрительное выполнение PowerShell с обфускацией
src 10.12.4.87 → dst 203.0.113.147 · suser CORP\a.ivanov
processName powershell.exe
CMDLINE      powershell.exe -nop -w hidden -enc JABzAD0A...
objectValue  HKCU\...\Run\OneDriveStandaloneUpdater
```

Читаем как аналитик: рабочая гипотеза

- Три часа ночи — легитимной деловой активности минимум
- `-w hidden -enc` — скрытый запуск и обфускация команды
- Ключ автозагрузки — классическое закрепление в системе
- Внешний `dst` — сам по себе не криминал
- Учётная запись обычного сотрудника — он вообще в курсе?

Гипотеза: возможное закрепление вредоносного кода.

Из полей — вопросы для проверки

Интерактив «Дежурная смена»

Вам на проверку — три карточки. На каждую не более минуты:
решение — «эскалация» или «заккрыть».

Карточка 1 · рабочий полдень

Антивирус обновил базы
Загрузка подписанного
процесса вендора

Карточка 2 · 03:00

PowerShell с обфускацией
как в демонстрационном
примере

Карточка 3 · рабочее время

Пользователь открыл PDF
из письма · сработало правило
на макросы

Что не хватило?

Почти всегда ответ — **контекст**:

история этой машины и этого пользователя, что было до и после

Карточка — снимок одного события, а не вся правда

ML-модель-советчик: что меняется

Обучена на размеченной истории → для каждой карточки —
оценка вероятности того, что это инцидент

Советчик — не решающий

Финальный вердикт — за аналитиком:

вероятность + опыт + контекст, которого у модели нет

Human-in-the-loop — человек в контуре управления
(аккуратный разбор — занятие 1.3)

Полезный совет должен быть **понятен** → XAI, модуль 3

Поля, которых SIEM не знает

Поле	Значение
Fact_label	Истинная метка: 1 — инцидент, 0 — легитимно
y_pred	Предсказание модели
y_pred_proba	Вероятность предсказания

Роль — на практике 1.5. Сейчас запомните: есть «ответы» и есть «подсказка»

Курс — интеграционный

Модели и метрики → дисциплины ML и статистики

Запросы к данным → базы данных

Контекст атак → курсы информационной безопасности

Код → программная инженерия

Наш вклад — собрать это в работающий продукт на сквозном кейсе

Итоги

- 01 Мир кейса: сотни тысяч карточек, шум преобладает, обе ошибки дороги
- 02 Конвейер: события → SIEM → правила → карточки → аналитик
- 03 Карточка — четыре группы полей
- 04 Модель — советчик; решение за человеком; совет должен быть объясним

Сегодня и на неделю

Сегодня, 12:00 — практика 1.5

- Фиксация треков
- Проверка инструментов: Qlik · Taipy
- Знакомство с датасетом

Самостоятельная работа

- «Меню кейсов» (СДО) — к 19.09
- К. Андерсон, главы о data-driven подходе — к 1.3

Далее: занятие 1.3

Понятийный аппарат анализа данных

DIKW · Data-Driven и Data-Informed · сигнал и шум · TP/TN/FN/FP

Вопросы?